МОДЕЛІ СКЛАДНОСТІ ТА ПРОДУКТИВНОСТІ ПАРАЛЕЛЬНИХ ПРОГРАМ

Питання ефективності паралельних програм

- Вище були розглянуті основні основні засоби паралельного програмування, зокрема, для взаємодій паралельних процесів.
- Проте з практичної точки зору виникають запитання: *як розробляти ефективні паралельні програми* і за якими критеріями оцінювати їх ефективність? Відповіді на них може дати *модель складності обчислень*.
- Відомими мірами складності для послідовних алгоритмів є *часова* T(n) складність алгоритмів, що вимірюється кількістю кроків (операцій), які необхідно виконати, і *просторова* складність S(n), що вимірюється кількістю пам′яті, яку необхідно мати для роботи алгоритму.
- Тут n – це *розмір вхідних даних*, що інтерпретуються відповідно до предметної області задачі, що розв′язується.
- Наприклад, якщо вхідними даними є числа, то таким розміром може бути довжина двійкового запису чисел, для графів – це кількість вершин, для матриць – порядок матриць і т д.

Складність паралельних обчислень

- Для паралельних алгоритмів часова і просторова складності також залишаються актуальними, але одержують свої особливості.
- По-перше, вони стають залежними від кількості процесорів p, на яких розв′язується задача: $T_p(n)$, $S_p(n)$.
- По-друге, одиницею виміру в $T_p(n)$ тепер є *паралельний обчислювальний крок, а не окрема операція*, тобто така сукупність операцій, що одночасно виконуються в складі обчислювального кроку як одна операція.
- І по-третє, сама просторова складність тепер визначається як кількість процесорів (як правило, максимальна), необхідна для вирішення задачі.

Модель RAM

- Для оцінки складності послідовних обчислень добре відомою є модель RAM (random access memory) машини з *пам′ятью довільного доступу*. Основними припущеннями цієї моделі є такі:
  - модель складається з *вхідної стрічки* (тільки для читання), *вихідної стрічки* (тільки для запису), *процесора та пам′яті;*
  - пам′ть являє собою *потенційно нескінченну множину регістрів N*, здатних зберігати числа довільної розрядності;
  - операції RAM-машини складають *функціонально повний набір* операцій.
- RAM-машина є, таким чином, *універсальною моделлю машини Т′юрінга*, що зберігає поліноміальні оцінки часової та просторової складності з точністю до числового коефіцієнта.

Модель паралельних обчислень PRAM

- Модель паралельних обчислень PRAM є *поширенням моделі RAM* за рахунок:
  - *збільшенні кількості процесорів* до N>1, яке є параметром моделі і визначається як функція розміру вхідних даних;
  - надання нескінченної множині регістрів властивості *спільного доступу* з боку процесорів;
  - розширення множини команд *командами читання та запису* спільної пам′яті.
- Така модель є абстракцією паралельних машин і не враховує важливі риси реальних систем: в моделі *не існує спеціальних засобів синхронізації*, але передбачається деяка стратегія для розв′язання конфліктів по спільній пам′яті. Крім того, в моделі PRAM *не враховуються втрат часу на обміни даними*.

Коефіцієнт прискорення паралельних обчислень

- Ідеально, алгоритм складності T_1 в RAM мусив би мати складність $T_n = T_1/n$ в моделі PRAM, де n – кількість процесорів.
- Проте це далеко не завжди так відбувається і визначається характеристиками паралелізму обчислень конкретних алгоритмів. Для оцінки реального прискорення обчислень на паралельній системі існує *коефіцієнт прискорення*:

$$S_n = T_1/T_n \leq n$$

- На практиці є ще ряд факторів, які можуть значно знижувати S_n:, а саме:
  - спільні ресурси (пам'ять, канали зв'язку) можуть стати *вузькими місцями* паралельної системи і знижувати її продуктивність;
  - паралельні процеси можуть втрачати час, *очікуючи виконання умов синхронізації*;
  - послідовна частина обчислень *може не мати паралельної реалізації*.

Закон Амдала (Amdahl) (1)

- Нехай $T_1 = T_s + T_p$, де T_s – час виконання послідовної частини, а T_p – паралельної (тобто такої, що допускає розпаралелювання) частини обчислень. Тоді

$$S_n = \frac{T_1}{T_n} \le \frac{T_s + T_p}{T_s + T_p / n}$$

- Введемо позначення для величини $x = T_s/(T_s + T_p)$, що не залежить від *n* і означає частку нерозпаралелюваного коду. Тоді:

$$S_n \le \frac{1}{x + (1 - x)/n}$$

- У такій формі залежність прискорення від співвідношення послідовної та паралельної частини обчислень відома під назвою *закону Амдала* (Amdahl).

Закон Амдала (Amdahl) (2)

- Якщо прийняти x=1/k, k>1, то можна одержати важливий практичний наслідок з цього запису: $S_n \leq k$.
- Тобто, прискорення завжди обмежене величиною, оберненою до частки послідовних обчислень. Наприклад, якщо k=0,1, то $S_n \leq 10$.
- Звідси випливає важливий висновок, що k=1/x є *максимальною кількістю процесорів*, на якій <u>доцільно</u> реалізувати паралельні обчислення для даної задачі.
- Закон Амдала свідчить про те, що залежність прискорення S_n від кількості процесорів є функцією *нелінійною*, що має уповільнення при збільшенні кількості процесорів.

Закон Амдала (Amdahl) (3)

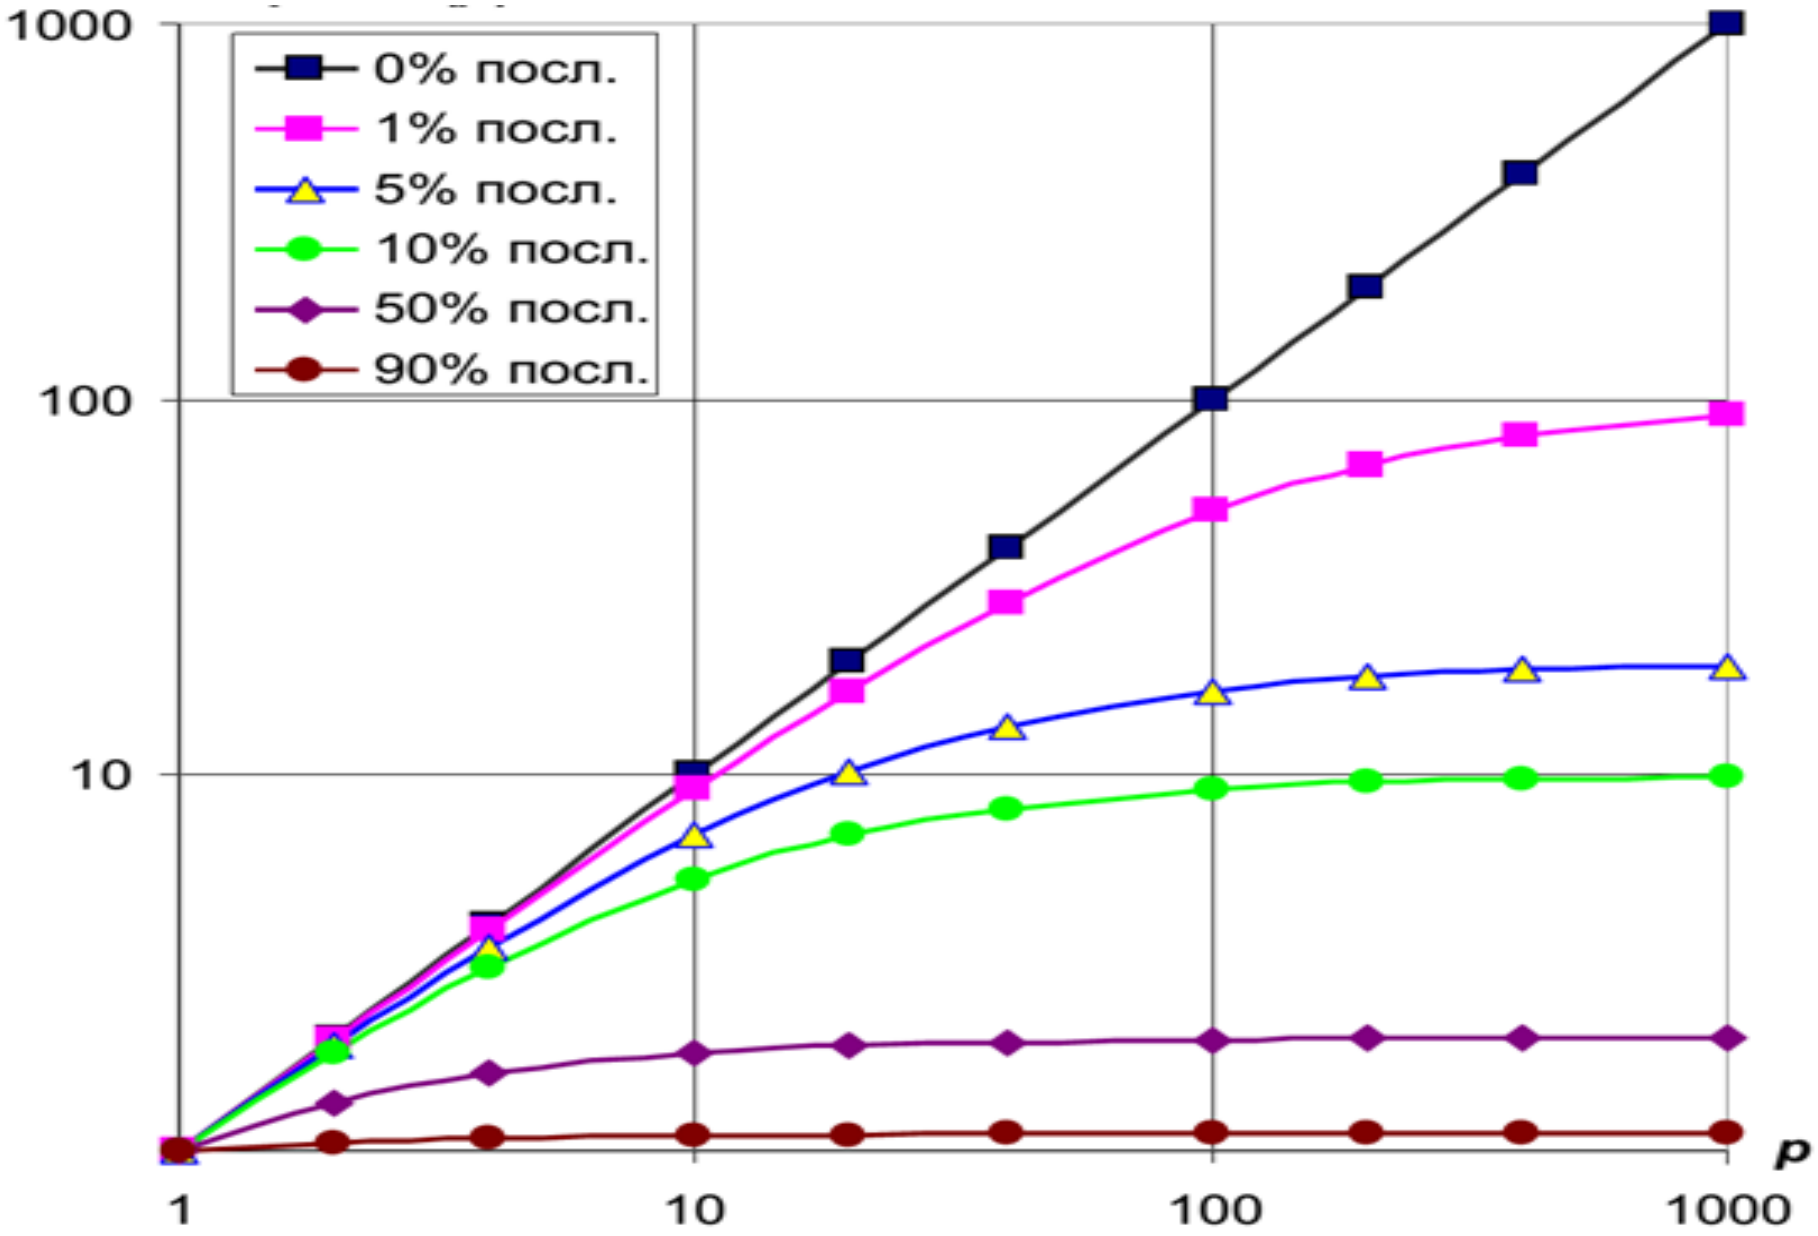

Коефіцієнт ефективності паралельних обчислень

- Для характеристики якісного використання процесорів для паралельних обчислень було запропоновано *коефіцієнт ефективності*:

$$E_n = \frac{T_1}{nT_n} = \frac{S_n}{n}$$

- З визначення випливає, що $0 \le E_n \le 1$, і, значить, коефіцієнт ефективності характеризує *питоме прискорення*, що припадає на один процесор.
- Таким чином, коефіцієнт ефективності паралельних обчислень має значення *коефіцієнта корисної дії* паралельної системи, що характеризує, наскільки ефективно використовується її обчислювальна потужність.
- Практично важливими є випадки, коли прискорення та ефективність паралельних обчислень є <u>лінійними</u> функціями кількості процесорів. У цих випадках паралельні алгоритми, що розв'язують задачі, і самі задачі називають *масштабованими* (scalable).

Явища суперлінійних прискорень

- Явища суперлінійних прискорень, що іноді може траплятись при паралельних обчисленнях є аномальними і пояснюються:
- 1) або додатковими апаратними можливостями мультипроцесорної системи, що сприяють покращенню продуктивності обчислень (наприклад використання додаткової кеш-пам’яті, якої у паралельної системи більше, ніж у послідовного процесора);
- 2) або наявністю ефекту "*синергетичної поведінки*", що відсікає частину роботи алгоритму (часом, значну), що виконується послідовним або "малопроцесорним" алгоритмом, але може не виконуватись за більшої кількості процесорів.

Ціна паралельних обчислень

- Крім критеріїв часу T_n (N), простору (процесорів) n, прискорення S_n(N) та ефективності E_n(N) використовують також інтегральний показник продуктивності паралельних алгоритмів, – <u>ціну</u> C_n (N) = T_n (N)*n, що інколи називають *роботою* по аналогії з фізикою.
- Для випадку *n*=1 маємо $C_1(N)=T_1(N)$.
- Тобто, для послідовних алгоритмів ціна співпадає з його часовою складністю, тому ціну можна сприймати як узагальнення часової складності послідовних алгоритмів.
- З цим поняттям пов′язане також поняття *оптимального* паралельного алгоритму, а саме такого, що C_n (n) =O(T_1(n)).

Принцип Брента (Brent) (1)

- Оцінка часової складності T_n, що розглядалася досі, була пов'язана з кількістю процесорів n.
- Проте часто буває цікаво знати <u>найкращу</u> оцінку часової складності паралельного алгоритму, тобто таку, що обчислюється при необмеженій кількості процесорів і від неї уже не залежить.
- Така величина називається часом *необмеженого розпаралелювання* і позначається T_∞.
- Зв′язок між кількістю процесорів та часом паралельного виконання встановлюється загальним *принципом Брента* (Brent) у наступній теоремі.

Принцип Брента (Brent) (2)

- **Теорема.** Якщо A – паралельний алгоритм, що потребує T_∞ кроків і оцінюється в C операцій, то A можна виконати на p процесорах за $O(C/p+ T_\infty)$ кроків, де $p<[n/2]$ і операції бінарні.
-
- <u>Доведення.</u> Нехай c_i – кількість операцій, що виконуються на i-ому кроці при необмеженому розпаралелюванні. Тоді на кожному кроці паралельних обчислень на p процесорах виконується не більше $c_i/p +1$ операцій. Позначимо $T_\infty=n$. Звідси маємо

$$T_p = \sum_1^n \left(\frac{c_i}{p} + 1 \right) = \frac{C}{p} + n$$

- І отже $T_p = O(c/p+T_\infty)=O(T_1/p+ T_\infty)$, що і треба було довести. ♦
- Теорема Брента характеризує *уповільнення обчислень* паралельних алгоритмів при використанні ними меншої кількості процесорів.